

ANÁLISE EXPLORATÓRIA DOS MICRODADOS DO ENEM 2020

ÍNDICE

1.Objetivo.....	2
2.Dataset.....	3
3.Tratamento dos dados	4
4.Análises realizadas.....	5
5.Conclusão.....	10

1.Objetivo

Este projeto tem como objetivo analisar os microdados do ENEM 2020, investigando como fatores socioeconômicos, como renda familiar e região, influenciam o desempenho dos estudantes.

2.Dataset

Os dados utilizados foram obtidos a partir dos Microdados do ENEM 2020 disponibilizados pelo INEP. Com o objetivo de minimizar o tamanho do arquivo, foi feita uma amostra a partir do arquivo csv original.

Fonte: <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>

3.Tratamento dos Dados

Devido ao grande volume de dados, foi criada uma amostra aleatória do dataset original para facilitar a análise.

Foram seleccionadas apenas as variáveis relevantes para o estudo.

A partir do arquivo original MICRODADOS_ENEM_2020 capturamos uma amostra aleatória com o seguinte código:

```
import pandas as pd

tamanho_amostra = 100000

amostras = []

for chunk in pd.read_csv(
    "../DADOS/MICRODADOS_ENEM_2020.csv",
    sep=';',
    encoding='latin1',
    chunksize=50000,
    low_memory=False
):

    amostra_chunk = chunk.sample(frac=0.1)

    amostras.append(amostra_chunk)

df_amostra = pd.concat(amostras)

df_amostra = df_amostra.head(tamanho_amostra)

df_amostra = df_amostra.head(tamanho_amostra)

df_amostra.to_csv(
    "../DADOS/enem_amostra.csv",
    index=False
)
```

4. Análises realizadas

4.1 Análise de renda

Começamos o estudo de como a renda influencia no desempenho do aluno. Para isso, criamos um dataframe com o arquivo csv da amostra, utilizando apenas as colunas de interesse.

	NU_NOTA_CN	NU_NOTA_CH	NU_NOTA_LC	NU_NOTA_MT	NU_NOTA_REDACAO	Q006
0	471.6	514.0	587.0	470.0	960.0	B
1	389.7	388.3	488.9	562.3	600.0	B
2	NaN	NaN	NaN	NaN	NaN	C
3	448.0	527.8	570.3	511.9	320.0	C
4	NaN	NaN	NaN	NaN	NaN	A

Observe que essa coluna “Q006” é referente à renda do aluno. Mais especificamente, essa é uma das questões respondidas no preenchimento de dados do aluno.

Q006	Qual é a renda mensal de sua família? (Some a sua renda com a dos seus familiares.)	A	Nenhuma Renda
		B	Até R\$ 1.045,00
		C	De R\$ 1.045,01 até R\$ 1.567,50
		D	De R\$ 1.567,51 até R\$ 2.090,00
		E	De R\$ 2.090,01 até R\$ 2.612,50
		F	De R\$ 2.612,51 até R\$ 3.135,00
		G	De R\$ 3.135,01 até R\$ 4.180,00
		H	De R\$ 4.180,01 até R\$ 5.225,00
		I	De R\$ 5.225,01 até R\$ 6.270,00
		J	De R\$ 6.270,01 até R\$ 7.315,00
		K	De R\$ 7.315,01 até R\$ 8.360,00
		L	De R\$ 8.360,01 até R\$ 9.405,00
		M	De R\$ 9.405,01 até R\$ 10.450,00
		N	De R\$ 10.450,01 até R\$ 12.540,00
		O	De R\$ 12.540,01 até R\$ 15.675,00
		P	De R\$ 15.675,01 até R\$ 20.900,00
		Q	Acima de R\$ 20.900,00

Tal informação está disponível no dicionário dos microdados do enem, disponibilizados pelo INEP.

Depois disso, criamos uma nova coluna chamada `nota_media`, que calcula a média das notas de cada aluno. Em seguida, renomeamos a coluna Q006 para “renda” e trocamos os dados de A,B,C... para a respectiva renda, e agrupamos o dataframe de acordo com a renda, calculando a média da coluna `nota_media` para cada agrupamento, o que nos deu o dataframe abaixo.


	renda	nota_media
0	Acima de R\$ 20.900,00	662.80
6	De R\$ 15.675,01 até R\$ 20.900,00	660.62
5	De R\$ 12.540,01 até R\$ 15.675,00	650.48
4	De R\$ 10.450,01 até R\$ 12.540,00	644.24
15	De R\$ 9.405,01 até R\$ 10.450,00	639.33
13	De R\$ 7.315,01 até R\$ 8.360,00	629.87
14	De R\$ 8.360,01 até R\$ 9.405,00	628.22
12	De R\$ 6.270,01 até R\$ 7.315,00	621.51
11	De R\$ 5.225,01 até R\$ 6.270,00	616.33
10	De R\$ 4.180,01 até R\$ 5.225,00	602.33
9	De R\$ 3.135,01 até R\$ 4.180,00	585.83
8	De R\$ 2.612,51 até R\$ 3.135,00	569.52
7	De R\$ 2.090,01 até R\$ 2.612,50	555.97
3	De R\$ 1.567,51 até R\$ 2.090,00	539.12
2	De R\$ 1.045,01 até R\$ 1.567,50	522.44
1	Até R\$ 1.045,00	496.85

Com essa visualização já podemos ver uma dependência forte entre a nota média e a renda de um estudante. Para seguir a análise, calculamos algumas estatísticas. Para isso, precisamos transformar a coluna renda em numérica, e por isso fizemos uma substituição para cada faixa de renda.

```
mapa_renda = {  
    'Nenhuma Renda': 0,  
    'Até R$ 1.045,00': 1,  
    'De R$ 1.045,01 até R$ 1.567,50': 2,  
    'De R$ 1.567,51 até R$ 2.090,00': 3,  
    'De R$ 2.090,01 até R$ 2.612,50': 4,  
    'De R$ 2.612,51 até R$ 3.135,00': 5,  
    'De R$ 3.135,01 até R$ 4.180,00': 6,  
    'De R$ 4.180,01 até R$ 5.225,00': 7,  
    'De R$ 5.225,01 até R$ 6.270,00': 8,  
    'De R$ 6.270,01 até R$ 7.315,00': 9,  
    'De R$ 7.315,01 até R$ 8.360,00': 10,  
    'De R$ 8.360,01 até R$ 9.405,00': 11,  
    'De R$ 9.405,01 até R$ 10.450,00': 12,  
    'De R$ 10.450,01 até R$ 12.540,00': 13,  
    'De R$ 12.540,01 até R$ 15.675,00': 14,  
    'De R$ 15.675,01 até R$ 20.900,00': 15,  
    'Acima de R$ 20.900,00': 16  
}  
  
df_renda["renda_num"] = df_renda["renda"].map(mapa_renda)
```

Calculamos então, a correlação, o slop, o intercepto e fizemos uma regressão linear com os dados.

Correlação entre renda e nota média: 0.9702951819885797
slop: [11.21333896]
intercepto: 503.2643295960682



Por fim, calculamos algumas estatísticas a mais dos dados.

	media	mediana	desvio_padrao	minimo	maximo	quantidade
renda						
Acima de R\$ 20.900,00	641.01	648.81	86.50	93.33	852.76	33324
Até R\$ 1.045,00	484.45	478.04	77.51	36.00	837.72	817187
De R\$ 1.045,01 até R\$ 1.567,50	507.83	502.30	80.41	66.67	833.38	453292
De R\$ 1.567,51 até R\$ 2.090,00	522.24	517.34	82.77	80.00	833.20	335243
De R\$ 10.450,01 até R\$ 12.540,00	620.98	627.12	86.81	103.73	845.80	31403
De R\$ 12.540,01 até R\$ 15.675,00	627.04	634.14	86.35	107.10	852.86	28598
De R\$ 15.675,01 até R\$ 20.900,00	634.08	642.12	85.86	163.55	847.12	27832
De R\$ 2.090,01 até R\$ 2.612,50	539.04	535.24	85.56	100.00	845.12	172038

4.2 Análise de região

Começamos tomando a nossa tabela com as colunas necessárias.

	SG_UF_ESC	NU_NOTA_CN	NU_NOTA_CH	NU_NOTA_LC	NU_NOTA_MT	NU_NOTA_REDACAO
0	NaN	471.6	514.0	587.0	470.0	960.0
1	NaN	389.7	388.3	488.9	562.3	600.0
2	CE	NaN	NaN	NaN	NaN	NaN
3	NaN	448.0	527.8	570.3	511.9	320.0
4	NaN	NaN	NaN	NaN	NaN	NaN

Depois, agrupamos por região mapeando cada sigla da primeira coluna. Após retirarmos linhas vazias, e criar novamente uma coluna com a nota_media, obtivemos uma tabela como abaixo.

	SG_UF_ESC	NU_NOTA_CN	NU_NOTA_CH	NU_NOTA_LC	NU_NOTA_MT	NU_NOTA_REDACAO
2	CE	NaN	NaN	NaN	NaN	NaN
19	SP	559.6	613.7	584.2	626.1	840.0
21	CE	391.4	532.7	507.9	517.5	480.0
26	SC	NaN	NaN	NaN	NaN	NaN
30	RO	668.9	606.0	603.9	848.3	700.0

	REGIÃO	nota_media
2	Nordeste	NaN
19	Sudeste	644.72
21	Nordeste	485.90
26	Sul	NaN
30	Norte	685.42

Finalmente, agrupamos por região e calculamos a média da coluna nota_media para cada região.

```
REGIÃO
Centro-Oeste    552.93
Nordeste        531.71
Norte           522.17
Sudeste         576.20
Sul             569.86
Name: nota media, dtype: float
```

5. Conclusão

A análise estatística por faixa de renda evidencia uma forte correlação positiva entre renda familiar e desempenho no ENEM.

Observa-se um crescimento progressivo das médias conforme a renda aumenta.

Participantes pertencentes às menores faixas de renda apresentaram desempenhos significativamente inferiores aos participantes de rendas mais elevadas.

Os estudantes sem renda declarada apresentaram média geral de 475.85, enquanto participantes com renda familiar de até R\$ 1.045,00 obtiveram média de 496.98.

Em contraste, estudantes pertencentes à faixa de renda acima de R\$ 20.900,00 apresentaram média de 661.74, a maior entre todos os grupos analisados.

A diferença entre os extremos de renda é de aproximadamente 164 pontos, indicando forte influência das condições socioeconômicas no desempenho acadêmico.

A análise estatística das notas médias do ENEM por região evidencia diferenças relevantes no desempenho dos participantes brasileiros.

A região Sudeste apresentou o maior desempenho médio (576.29) e também a maior mediana (574.76), indicando um nível elevado e relativamente consistente de desempenho entre os estudantes da região. Em seguida aparecem as regiões Sul (569.86) e Centro-Oeste (553.30).

As menores médias foram observadas nas regiões Nordeste (531.71) e Norte (522.17), sugerindo desigualdades regionais no desempenho educacional.

Os desvios padrão variam entre aproximadamente 88 e 91 pontos, indicando uma dispersão significativa das notas em todas as regiões. O Nordeste apresentou o maior desvio padrão (98.94), o que sugere maior heterogeneidade no desempenho dos participantes da região.

Já o Sul apresentou o menor desvio padrão (88.22), indicando notas mais homogêneas.

Observa-se também que, em todas as regiões, as medianas são ligeiramente menores que as médias. Isso sugere a existência de participantes com notas muito elevadas influenciando a média regional.

As regiões Sudeste (6037) e Nordeste (5988) concentram a maior quantidade de participantes da amostra analisada.

De forma geral, os resultados sugerem que fatores socioeconômicos, infraestrutura educacional e desigualdades regionais podem impactar significativamente o desempenho dos estudantes no ENEM.